

## МОДЕЛИРОВАНИЕ И СИСТЕМНЫЙ АНАЛИЗ

УДК 621.396.96:004.021

МЕТОДЫ РАСПОЗНАВАНИЯ ДИНАМИЧЕСКИХ ОБЪЕКТОВ  
В РАДИОЛОКАЦИОННОМ ПРОСТРАНСТВЕ

Н. Л. Князев, Л. А. Денисова

*Омский государственный технический университет, г. Омск, Россия**DOI: 10.25206/2310-9793-2017-5-4-152-158*

**Аннотация** – Рассмотрено применение методов кластерного анализа для решения задачи обнаружения летательных аппаратов на основе распределения выборки навигационных параметров по группам (кластерам). Предложен модифицированный метод кластерного анализа, выполняющий поиск и обнаружение объектов, итерационное объединение их в кластеры, с последующим пересчетом их количества для повышения точности распознавания летательных аппаратов. Рассмотрен ход работы метода и особенности реализации. Показана эффективность предлагаемого метода для точного кластерного анализа обнаруженных целей.

**Ключевые слова:** радиолокация, нечеткая кластеризация, метрика, итерации.

## I. ВВЕДЕНИЕ

Главной задачей контроля использования воздушного пространства является выявление степени опасности наблюдаемых летательных аппаратов (ЛА) и их распределение по соответствующим группам: самолет, терпящий бедствие, нарушитель государственной границы, неопознанный воздушный объект и др. В условиях войны обнаружение и распознавание средств воздушного нападения (СВН) необходимо для их ранжирования по приоритету, последующего целераспределения средствам ПВО и уничтожения.

Распознавание целей в воздушном пространстве является задачей радиолокации. Анализ пространства и определение параметров движения объектов (навигационных параметров) происходит при помощи радиолокационных станций (РЛС) [1]. Для обнаружения ЛА, а тем более их идентификации (определения принадлежности к определенному классу или типу) создаются и совершенствуются информационные системы, работающие в радиолокационном диапазоне волн. В этих целях наиболее широко применяются методы кластеризации «обучения с учителем» и «обучения без учителя» [2]. Понятие термина «обучение с учителем» означает, что заранее предоставлена дополнительная информация об исследуемых данных. Также «обучение с учителем» имеет место на этапе детализирования решения, качество которого обеспечивается специалистом. «Обучение с учителем» означает, что не требуется предоставление дополнительной информации и обычно включает в себя методы четкой кластеризации и плотностные методы кластеризации. К «обучению без учителя» можно отнести задачу нечеткой кластеризации, поскольку в идеальном случае не требует предоставления дополнительной информации. При кластерном анализе метки исходных объектов изначально не заданы, и даже может быть неизвестно само входное множество.

Летательные аппараты характеризуются следующими основными навигационными параметрами:

- несущей частотой  $f_c$ , определяющей в каком диапазоне частот работает искомая цель;
- мощностью сигнала  $P$ , по которой можно оценить дальность объекта;
- курс самолета  $\nu$ , по которому оценивается направление самолета в пространстве;
- углом крена  $\gamma$  и углом тангажа  $\psi$ , необходимыми для определения положения ЛА относительно его продольных и поперечных осей.

Сложность проблемы решения данной задачи обусловлена сложностью выделения летательных аппаратов в заданном частотном диапазоне. Трудности заключаются в том, что обширное распространение получили сети мобильной связи 4G, работающие в том же диапазоне частотного канала и затрудняющие обработку данных. Это вынуждает усовершенствовать алгоритмы определения динамических объектов в пространстве.

## II. ПОСТАНОВКА ЗАДАЧИ

Пусть имеется последовательность навигационных параметров, представленных в виде входного вектора характеристик  $p$ -объекта в воздушном пространстве  $x^p = (x_1^p, x_2^p, \dots, x_i^p, \dots, x_N^p)$ , где  $p = \overline{1, |X|}$  – порядковый

номер летательного аппарата из входного множества летательных объектов  $X$ ,  $x_i^p$  –  $i$ -е свойство  $p$ -го ЛА,  $i = \overline{1, N}$ ,  $N$  – входное множество характеристик летательного объекта  $x_i^p$ .

Множество летательных объектов  $X$ , с помощью выбранного метода кластеризации (см. п. 5) динамически разбивается на группы (*кластеры*). Созданные кластеры  $c_j$  содержат в себе навигационные параметры  $p$ -го летательного аппарата  $c_j = (x^1, \dots, x^i)$   $x^i \in X$ , где  $j = \overline{1, M}$ ,  $M$  – количество кластеров. Каждый входной летательный аппарат (далее объект) должен быть отнесен к одному из имеющихся кластеров  $c_j$ .

В качестве математического описания степени сходства объектов, применяется метрика (скалярная величина) – расстояние  $d(x, y)$  между двумя объектами  $x$  и  $y$ . По условия задачи кластеризации функция метрики имеет условия неотрицательности, симметричности, а также неравенство треугольника [3]:

$$\begin{aligned} d(x, y) &> 0, \text{ причем } d(x, y) = 0 \Leftrightarrow x = y, \\ d(x, y) &= d(y, x), \\ \forall y, d(x, z) &\leq d(x, y) + d(y, z). \end{aligned} \quad (1)$$

Наиболее распространенным расстоянием является *Евклидово* [4]. Оно представляет собой геометрическое расстояние в многомерном пространстве:

$$d(x^p, c_j) = \sqrt{\sum (x_i^p - c_m)^2}. \quad (2)$$

Сфера применения Евклидова расстояния, ограничена однородностью характеристики объекта по физическому смыслу. Его применение оправдано, в том случае, если метрическое пространство совпадает с геометрическим пространством. Характеризующими параметрами кластера являются: *центр*  $m(c_j)$ , который определяется следующим образом:

$$m(c_j) = \sum_{i=1}^N u_{ij} x^p,$$

где  $u_{im}$  – элемент матрицы разбиения  $U$ , такой что:

$$u_{ij} = \begin{cases} 1, & \text{при } d(x^p, c_j) \rightarrow \min; \\ 0, & \text{в остальных случаях.} \end{cases}$$

и радиус кластера  $R$  являющийся расстоянием между ядром кластера и максимально удаленным от ядра объектом  $x^p$ :

$$R = \max(d(x^j - c_j)), x^j \in c_j.$$

### III. МЕТОДЫ КЛАСТЕРНОГО АНАЛИЗА ВОЗДУШНОГО ПРОСТРАНСТВА

В большинстве современных систем обработки навигационных параметров, получаемых от РЛС, используется два вида методов кластеризации:

- «обучение с учителем» – отличается тем, что априорно имеется дополнительная информация об входных объектах. Реализация данного вида кластеризации находит место в методах четкой кластеризации *k-means*;
- «обучение без учителя» – отличается тем, что информация касательно объектов неизвестна, также и не известно их точное количество. Обычно задачи анализа данных подобного типа, используют методы нечеткой кластеризации *c-means*.

Четкая кластеризация методом *k-means* [5] разбивает множество объектов некоторого (в основном векторного) пространства на известное заранее количество кластеров  $M$ . Объекты  $x^p$  делятся на кластеры вновь и вновь, в соответствии с тем, какой из новых центров оказался ближе по выбранной метрике. Цель данного метода минимизировать среднеквадратичное отклонение на точках каждого кластера. Цикл заканчивается после прохождения заданного (априорно) числа итераций.

Нечеткая кластеризация методом *c-means* [6] также производит разбиение входного множества объектов на кластеры. Однако его различие заключается в применении функции принадлежности  $\mu(x^p) \in [0, 1]$ , которая определяет степень принадлежности объекта к кластеру. С учетом данного факта, метод *c-means* не требует устанавливать конкретное количество кластеров, с введением некоторого условия останова метода.

В том случае, когда оператор точно определяет число целей (динамических объектов в пространстве), с помощью визуального анализа экрана индикатора вычислительного комплекса военного объекта (ВКВО), распре-

деление целей на алгоритмическом уровне не потребует усложненных методов кластеризации, таких как *c-means*, и достаточную эффективность проявит метод *k-means*. Но в ситуации, когда количество летательных аппаратов визуально точно определить не выходит и стандартные методы распознавания становятся, менее эффективны, наилучшим вариантом будет использование метода *c-means*. Однако для решения поставленной задачи, требуется внести некоторые модификации в существующий метод, для повышения точности определения ЛА.

#### IV. МОДИФИЦИРОВАННЫЙ МЕТОД *FCR\_DV*

Методы кластеризации на основе математического аппарата нечеткой логики эффективны в поисках близких по метрике объектов. Это объясняется тем фактом, что метод *c-means* точнее производит построение матрицы принадлежности  $U$ , благодаря функции принадлежности  $\mu(x^p)$ . Однако для повышения эффективности кластерного анализа, метод требуется модифицировать. Модификация метода *FCR\_DV* (*Fuzzy Clustering with Recalculation and Deleting Void*) заключается в следующем:

- повторный пересчет центров и радиусов кластеров для распределения объектов в них;
- введение критериев близости кластеров и процедуры оценки;
- проведение проверки на объединение близких кластеров по специальным критериям;
- определение и удаление пустых кластеров.

Пусть определение принадлежности объекта к кластеру вычисляется с помощью гауссовской симметричной функции принадлежности  $\mu(x^p)$  [7]:

$$\mu(x^p) = \exp \left[ - \left( \frac{x_i^p - c_j}{2 \cdot \delta} \right)^2 \right], \quad (3)$$

где  $\delta$  – параметр настройки функции принадлежности, равный расчетному количеству кластеров на шаге инициализации. Тогда степень принадлежности вектора  $x^p$  к кластеру будет найдена из выражения:

$$\mu(x^p) = \max [\mu(x_1^p), \mu(x_2^p), \dots, \mu(x_i^p), \dots, \mu(x_N^p)].$$

Для того чтобы учесть степень принадлежности объектов к двум ближайшим кластерам  $c_j$  и  $c_k$ , где  $k \neq j$ ,  $k \in M$ , введем изменения в формулу (2), с учетом формулы (3). Тогда функция расстояния (метрика) примет следующий вид:

$$d(x^j, c_k) = \sqrt{\sum \mu(x^j) \cdot (x_i^j - c_k)^2}, x_j \notin c_k.$$

Значения  $\mu(c_j)$  возрастают при уменьшении расстояния между вектором данных объекта и кластером. Таким образом, чем больше значение функции принадлежности  $\mu(c_j) > \mu(c_k)$ ,  $k \neq j$ , тем ближе расположены в пространстве кластеры  $c_m$  и  $c_k$ , а критерием объединения двух кластеров будет служить радиус кластера. Чем больше удалены объекты от кластеров, тем меньше значение  $\mu$  будет для принятия решения об объединении.

Предположим, требуется объединить в кластер два объекта с навигационными параметрами  $x^1$ ,  $x^2$  и при вычислении функций принадлежности (2), их степени оказались равны, т.е.  $\mu(x^1) = \mu(x^2) = 0,5$ . При близких значениях можно считать, что мерой близости является выражение:

$$\tilde{d} = |\mu(x^p) - \mu(x^k)|.$$

Тогда критерием объединения кластеров станет выражение:

$$\alpha = \left( \left| \min(\mu(x^1), \min(\mu(x^2))) \right| - 0,5 \right) \geq \tilde{d}.$$

Однако после проведения кластеризации очередного входного вектора  $x^p$ , некоторые кластеры могут не иметь принадлежащих им векторов объектов данных. Следовательно, они должны быть удалены из списка, т.е. удалены из множества кластеров (табл. 1).

ТАБЛИЦА 1  
РАСЧЕТНЫЕ ЗНАЧЕНИЯ КРИТЕРИЯ ОБЪЕДИНЕНИЯ БЛИЗКИХ КЛАСТЕРОВ

Кластеры	Мера близости кластеров $\tilde{d}$	Критерий объединения $\alpha$	Принятие решения
Кластеры № 1 и № 2	0,8	$ (0,9 - 0,5)  \leq 0,8$ или $ (0,1 - 0,5)  \leq 0,8$	Не объединять
Кластеры № 2 и № 3	0,4	$ (0,9 - 0,5)  \geq 0,4$ или $ (0,3 - 0,5)  \leq 0,4$	Объединить
Кластеры № 1 и № 3	0,7	$V(3) = 0$	Пустой кластер

Для выявления пустых кластеров вводится переменная  $V(j)$ , удовлетворяющая равенству

$$\sum_{j=1}^M V(j) = L,$$

где  $L$  – количество объектов в исходной выборке.

Структурно схема метода  $FCR\_DV$  представлена на рис. 1.

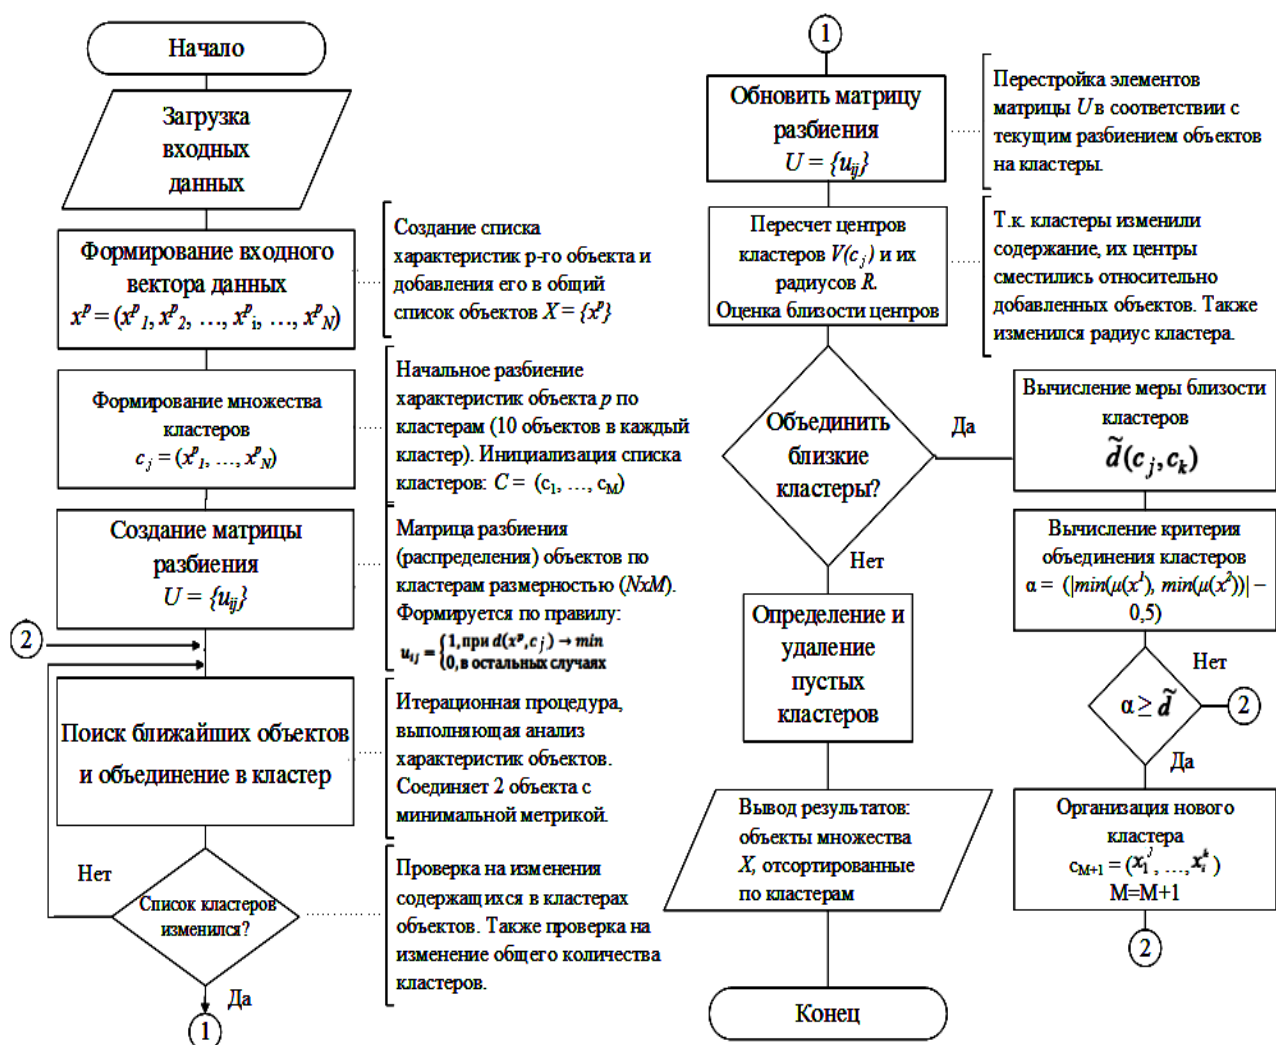


Рис.1. Схема работы метода  $FCR\_DV$

## V. ОПИСАНИЕ ЭКСПЕРИМЕНТОВ И РЕЗУЛЬТАТЫ

Для того чтобы продемонстрировать эффективность предлагаемого решения, проводится сравнительный анализ его работы с методом кластеризации *c-means*. В качестве исходных данных использованы навигационные параметры: несущая частота  $f_c$ , мощность  $P$ , курс  $\nu$ , крен  $\nu$ , тангаж  $\psi$ . Исходные данные сформированы при помощи специализированного пакета программного обеспечения, состоящего из двух программных модулей. При помощи первого модуля промоделированы траектории полета 40 летательных аппаратов. Второй модуль предназначен для формирования пачки импульсов для моделируемой траектории. Реализация предлагаемого метода *FCR\_DV* выполнена на языке программирования C#. Метод *c-means* реализован при помощи инструментария программы *STATISTICA 10* [8] фирмы StatSoft.

В итоге, выполнен экспериментальный кластерный анализ (см. табл. 2) при помощи описанных выше методов (проведено семь экспериментов). Относительная погрешность была рассчитана с помощью метода Стюдента [9].

ТАБЛИЦА 2  
РЕЗУЛЬТАТЫ РАБОТЫ МЕТОДОВ КЛАСТЕРИЗАЦИИ

Навигационные параметры	Метод кластеризации	Количество ЛА	Количество итераций	Количество экспериментов	Относительная погрешность метода
Несущая частота $f_c$ , МГц	<i>c-means</i>	35	11	5	2,2%
		33	13	2	
	<i>FCR_DV</i>	<b>43</b>	<b>21</b>	<b>6</b>	<b>1,3%</b>
		45	23	1	
Мощность $P$ , дБм	<i>c-means</i>	38	12	6	2,7%
		42	13	1	
	<i>FCR_DV</i>	<b>40</b>	<b>21</b>	<b>5</b>	<b>0,9%</b>
		39	23	2	
Курс $\nu$ , град.	<i>c-means</i>	42	12	5	4,7%
		37	17	2	
	<i>FCR_DV</i>	<b>40</b>	<b>27</b>	<b>5</b>	<b>0,9%</b>
		39	27	2	
Крен $\nu$ , град.	<i>c-means</i>	39	12	7	0,01%
	<i>FCR_DV</i>	<b>40</b>	<b>20</b>	<b>7</b>	0%
Тангаж $\psi$ , град.	<i>c-means</i>	39	12	7	0,01%
	<i>FCR_DV</i>	<b>40</b>	<b>20</b>	<b>7</b>	0%

## VI. ОБСУЖДЕНИЕ РЕЗУЛЬТАТОВ

В итоге проведения семи экспериментов, были получены статистические данные об распознанных летательных аппаратах. Проводя анализ табл. 2, нужно отметить тот факт, что, в общем, погрешность метода *FCR\_DV* значительно меньше чем метода *c-means*. Однако стоит отметить некоторые параметры, в которых анализ не показал полной эффективности.

К примеру, по анализу по несущей частоте видно, что оба метода не распознали точное количество летательных аппаратов. Метод *c-means* распознал около 33–35 ЛА, что меньше истинного количества объектов  $|X| = 40$ . В тоже время, метод *FCR\_DV* распознал 43–45 ЛА, что превышает истинное количество. Однако учитывая разницу между числом необнаруженных ЛА и лишних ЛА, улучшение наблюдается именно в результатах метода *FCR\_DV*, т.к. с точки зрения радиолокации лучше распознать на 3 цели больше, чем не обнаружить 5 достоверных целей.

Анализ по мощности продемонстрировал лучше результаты, чем предыдущий (рис. 2). Благодаря кластерному анализу через *c-means* обнаружено от 38 до 42 летательных аппаратов, причем в подавляющем числе экспериментов найдено именно 38 ЛА. Метод *FCR\_DV* распознал 39–40 объектов, что демонстрирует его эффективность относительно истинного числа летательных объектов.




Рис. 2. Сравнение точности распознавания ЛА (кривая 1 – метод *c-means*; кривая 2 – метод *FCR\_DV*): а) – по несущей частоте; б) – по мощности

Если рассматривать анализ по курсу, крену или тангажу (кластерный анализ по крену и тангажу одинаковый), можно увидеть один общий момент, связывающий два графика (рис. 3). Точность обнаружения летательных аппаратов, различается на 1–2 необнаруженных ЛА, причем методом *c-means*, что не является критичным. Кластерный анализ по двум углам: крен и тангаж, продемонстрировал одинаковые результаты. Основываясь на этом, можно утверждать, что результаты обоих методов по числу обнаруженных объектов схожи и практически не различаются, однако различие состоит в количестве итераций. Вероятно большее количество итераций метода *FCR\_DV*, способствует увеличению точности распознавания. Но в тоже время, при наличии другой выборки данных, предлагаемый метод *FCR\_DV* проигрывает в скорости методу *c-means*.




Рис. 3. Сравнение точности распознавания ЛА (кривая 1 - метод *c-means*; кривая 2 - метод *FCR\_DV*): а) – по курсу; б) – по крену

Эффективность метода *FCR\_DV* также состоит в удалении и перерасчете центров и радиусов кластеров, что позволяет оптимально располагать объекты относительно их «координат» в метрическом пространстве (см. рис. 4).

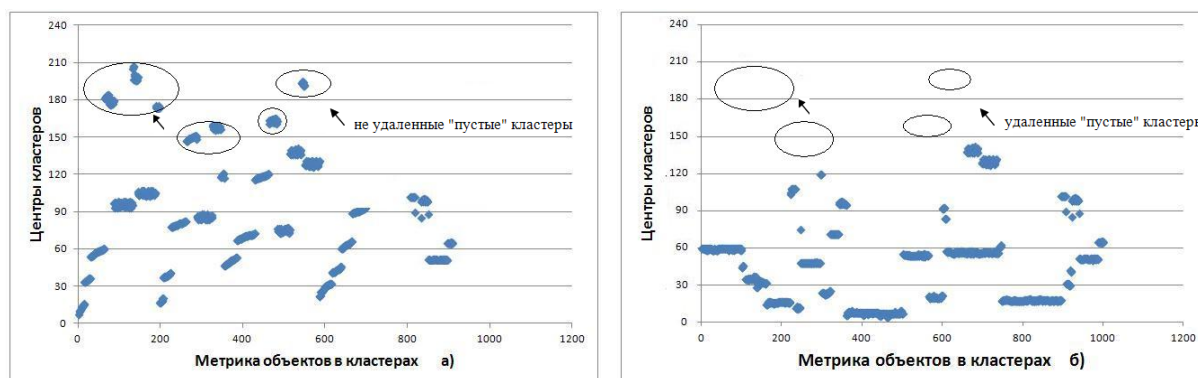


Рис. 4. Распределение объектов по кластерам: а) – метод *c-means*; б) – метод *FCR\_DV*



## VII. ВЫВОДЫ И ЗАКЛЮЧЕНИЕ

Предложенный алгоритм кластеризации *FCR\_DV* является модификацией алгоритма нечеткой кластеризации *c-means*. Алгоритм предоставляет возможность определять количество кластеров в процессе работы и проводить повторную реорганизацию кластеров, определять и удалять пустые кластеры для повышения точности распознавания. С помощью модифицированного алгоритма *FCR\_DV* удалось выделить большее количество летательных аппаратов, чем с помощью алгоритма *c-means*. Однако количество итераций *FCR\_DV* выше, чем у метода *c-means*. Данный факт говорит о том, что при наличии выборки большего объема для проведения кластерного анализа потребуется больше времени. Однако с учетом темпов развития производительности современных компьютеров можно надеяться, что данный недостаток не будет серьезной проблемой.

## СПИСОК ЛИТЕРАТУРЫ

1. Бакулев П. А. Радиолокационные системы. М.: Радиотехника, 2004. 286 с.
2. Барсегян А. А., Куприянов М. С., Степаненко В. В., Холод И. И. Методы и модели анализа данных: OLAP и Data Mining. СПб.: БХВ-Петербург, 2004. 336 с.
3. Нейский И. М. Классификация и сравнение методов кластеризации. URL: [http://it-claim.ru/Persons/Neyskiy/Article2\\_Neyskiy.pdf](http://it-claim.ru/Persons/Neyskiy/Article2_Neyskiy.pdf) (дата обращения: 02.05.2017).
4. Котов А. Н., Красильников Н. Кластеризация данных. 1988. С. 13–15. URL: <http://logic.pdmi.ras.ru/~yura/internet/02ia-seminar-note.pdf> (дата обращения: 05.02.2017).
5. Jiangsheng Y. Clustering Methods. Applications of Multivariate Statistical Analysis. Beijing: Institute of Computational Linguistics. 2008. 20 с. URL: <http://www.archive.org/web/20030422001200/icl.pku.edu.cn/yujs/papers/pdf/clster.pdf> (дата обращения: 07.03.2017).
6. Roubos J. A., Setnes M., Abonyi J. Learning Fuzzy Classification Rules from Labeled Data. Delft: Delft University of Technology. 2006. 17 с. URL: [http://www.researchgate.net/publication/222657076\\_Learning\\_fuzzy\\_classification\\_rules\\_from\\_labeled\\_data/links/09e4150879582c877f000000](http://www.researchgate.net/publication/222657076_Learning_fuzzy_classification_rules_from_labeled_data/links/09e4150879582c877f000000) (дата обращения: 05.05.2017).
7. Вешкурцев Ю. М., Бычков Е. Д., Титов Д. А. Цифровой фильтр на основе теории нечетких множеств с адаптивно изменяемыми функциями принадлежности // Известия вузов России. Радиоэлектротехника. 2007. Вып. 2. С. 43–50.
8. Statistica. Advanced analytics software package / Official WebSite, 2010. URL: <http://www.statistica.io> (дата обращения: 25.03.2017).
9. Петров П. К., Семин Ю. Н. Математико-статистическая обработка и графическое представление результатов педагогических исследований с использованием информационных технологий: учеб. пособие, Ижевск: Изд-во «Удмуртский университет», 2013. 179 с.

УДК 658.26:620.92.001.57

# МЕТОДИЧЕСКИЕ АСПЕКТЫ СИСТЕМНОГО АНАЛИЗА ЭФФЕКТИВНОСТИ ТОПЛИВНЫХ СИСТЕМ ПРЕДПРИЯТИЙ ПЕРЕРАБОТКИ УГЛЕВОДОРОДНОГО СЫРЬЯ

А. В. Кульбякина, И. В. Долотовский

Саратовский государственный технический университет имени Гагарина Ю.А., г. Саратов, Россия

DOI: 10.25206/2310-9793-2017-5-4-158-165

**Аннотация** – В статье рассматриваются методические положения системного анализа эффективности функционирования топливных систем предприятий переработки углеводородного сырья (УВС). Современные объекты переработки УВС – это крупные потребители энергетических ресурсов (ЭР) на собственные нужды. Снижение потребления ЭР, в том числе топливопотребления, а также создание рациональной структуры топливных систем – сложная и актуальная научная задача, решение которой возможно только с использованием методов системного анализа и синтеза сложных систем. В соответствии с принципами системного анализа, на основных этапах исследования разработана иерархическая структура топливной системы, блочная схема синтеза оптимального варианта топливной системы с использованием математических моделей и комплекса критериев эффективности. Приведены результаты от внедрения конкретных технических решений по созданию собственных источников энергообеспечения объектов переработки УВС.